

```
1 import pandas as pd
2 import glob
3 import os
```

```
1 from google.colab import drive
2 drive.mount('/content/drive')
```

Mounted at /content/drive

✓ อ่านไฟล์ CSV

```
1 folder_path = '/content/drive/MyDrive/EDA_ScopusData_Midterm/data/'
2 all_files = glob.glob(os.path.join(folder_path, "*.csv")) #หาไฟล์ที่ลงท้ายด้วย.csv
3
4 #ลิสต์สำหรับเก็บดาต้าเฟรมของแต่ละไฟล์
5 df_list = []
6
7 for file in all_files:
8     temp_df = pd.read_csv(file, encoding='utf-8')
9     #ดึงชื่อไฟล์ออกและตัด.csv แล้วสร้างคอลัมน์ subject
10    subject_name = os.path.basename(file).replace('.csv', '')
11    temp_df['Subject'] = subject_name
12
13    #เอาดาต้าเฟรมไปเก็บไว้ในลิสต์
14    df_list.append(temp_df)
15
16 df = pd.concat(df_list, ignore_index=True)
17 print(f"จำนวนข้อมูลทั้งหมด: {df.shape[0]} แถว, {df.shape[1]} คอลัมน์")
18 display(df.head())
```

จำนวนข้อมูลทั้งหมด: 5600 แถว, 23 คอลัมน์

	Authors	Author full names	Author(s) ID	Title	Year	Source title	Volume	Issue	Art. No.	Page start	...	Link	Abstract	
0	Xia X.; Yuruk N.; Wang Y.; Zhai X.	Xia, Xin (58544876200); Yuruk, Nejla (22959323200);	58544876200; 22959323200; 59936586800; 5719268...	Using Learning Progressions to Guide AI Feedba...	2027	Lecture Notes in Computer Science	16585 LNAI	NaN	NaN	195.0	...	https://www.scopus.com/pages/publications/1050...	Generative artificial intelligence (AI) offers...	F G In
1	Leite R.; Araújo R.E.	Leite, Renato (60707898100); Araújo, Rui Estev...	60707898100; 23395865700	Machine Learning on Small Datasets Under Resou...	2027	IFIP Advances in Information and Communication...	790 IFIPAICT	NaN	NaN	71.0	...	https://www.scopus.com/pages/publications/1050...	Artificial Intelligence AI is increasingly pre...	Int E
2	Hosseinhashemi S.; Liu Q.; Eisa A.; Saifoori S...	Hosseinhashemi, Somayeh (58629984100); Liu, Qi...	58629984100; 60751131200; 60571652000; 5719771...	Physics-Inspired hybrid AI framework for mecha...	2027	Chemical Engineering Science	338	NaN	124680	NaN	...	https://www.scopus.com/pages/publications/1050...	Modern chemical engineering requires robust ph...	
3	Khalid O.; Gamazo-Real J.-C.; Roibás-Millán E.	Khalid, Omer (60744895700); Gamazo-Real, Jose-...	60744895700; 36503715200; 56808339300	Run-Time Assurance for Onboard COTS-Based AI i...	2027	Lecture Notes in Computer Science	16767 LNCS	NaN	NaN	445.0	...	https://www.scopus.com/pages/publications/1050...	Safety-critical systems are increasingly apply...	Int Co
4	Shen A.; Yuan M.; Huang Q.; Feng B.; Du J.; Ma...	Shen, Ao (58769364200); Yuan, Mingzhi (5744468...	58769364200; 57444680700; 59423106600; 5799585...	Functional guidance for whole-protein virtual ...	2027	Information Fusion	138	NaN	104709	NaN	...	https://www.scopus.com/pages/publications/1050...	Virtual screening (VS) for protein targets lac...	Co

5 rows × 23 columns

▼ การกรองซ้ำ

```

1 # เก็บเฉพาะบทความที่ไม่ปรากฏซ้ำใน Subject อื่น (เช็คจากชื่อเรื่อง)
2 df = df.drop_duplicates(subset=['Title'], keep=False)
3
4 print(f"จำนวนข้อมูลหลังลบรายการซ้ำ: {df.shape[0]} แถว")

```

จำนวนข้อมูลหลังลบรายการซ้ำ: 5036 แถว

▼ หา Missing Value

```

1 #หา Missing Value ในแต่ละคอลัมน์
2 print("จำนวน Missing Value ในแต่ละคอลัมน์:")

```

```

3 missing_count = df.isnull().sum()
4 print(missing_count)
5
6 print("-" * 30)
7
8 #คำนวณเป็นเปอร์เซ็นต์ให้เห็นภาพแจ่มแจ้ง
9 print("ร้อยละ (%) ของ Missing Value ในแต่ละคอลัมน์:")
10 missing_percent = (df.isnull().sum() / len(df)) * 100
11 print(missing_percent.round(2))
12
13 print("-" * 30)
14
15 #แสดงเฉพาะคอลัมน์ที่มี Missing Value
16 missing_only = missing_percent[missing_percent > 0]
17 if not missing_only.empty:
18     print("คอลัมน์ที่มี Missing Value (เรียงจากมากไปน้อย):")
19     print(missing_only.sort_values(ascending=False).round(2))
20 else:
21     print("ไม่มี Missing Value ในชุดข้อมูลนี้")

```

จำนวน Missing Value ในแต่ละคอลัมน์:

Authors	45
Author full names	45
Author(s) ID	45
Title	0
Year	0
Source title	0
Volume	581
Issue	3637
Art. No.	2533
Page start	2697
Page end	2700
Cited by	0
DOI	66
Link	0
Abstract	0
Author Keywords	336
Index Keywords	340
Document Type	0
Publication Stage	0
Open Access	3325
Source	0
EID	0
Subject	0

dtype: int64

ร้อยละ (%) ของ Missing Value ในแต่ละคอลัมน์:

Authors	0.89
Author full names	0.89
Author(s) ID	0.89
Title	0.00
Year	0.00
Source title	0.00
Volume	11.54
Issue	72.22
Art. No.	50.30
Page start	53.55

```

Page end      53.61
Cited by      0.00
DOI           1.31
Link          0.00
Abstract      0.00
Author Keywords 6.67
Index Keywords 6.75
Document Type 0.00
Publication Stage 0.00
Open Access   66.02
Source        0.00
EID           0.00
Subject       0.00
dtype: float64
-----
คอลัมน์ที่พบ Missing Value (เรียงจากมากไปน้อย):
Issue          72.22
Open Access    66.02
Page end       53.61
Page start     53.55

```

1 df.columns

```

Index(['Authors', 'Author full names', 'Author(s) ID', 'Title', 'Year',
      'Source title', 'Volume', 'Issue', 'Art. No.', 'Page start', 'Page end',
      'Cited by', 'DOI', 'Link', 'Abstract', 'Author Keywords',
      'Index Keywords', 'Document Type', 'Publication Stage', 'Open Access',
      'Source', 'EID', 'Subject'],
      dtype='object')

```

▼ จัดการ Missing Value

```

1 import re
2 import nltk
3 from nltk.corpus import stopwords
4 nltk.download('stopwords')
5
6
7 columns_to_drop = [
8     'Volume', 'Issue', 'Art. No.', 'Page start',
9     'Page end', 'Open Access', 'EID', 'Link', 'Source'
10 ]
11 df_clean = df.drop(columns=columns_to_drop)
12
13 text_fill_cols = ['Author Keywords', 'Index Keywords', 'Authors', 'Author full names', 'Author(s) ID', 'DOI']
14 for col in text_fill_cols:
15     df_clean[col] = df_clean[col].fillna('')
16
17
18 stop_words = set(stopwords.words('english'))
19 custom_noise = [
20     'copyright', 'license', 'springer', 'nature', 'switzerland',
21     'authors', 'exclusive', 'pte', 'ltd', 'rights', 'reserved',

```

```

22     'ag', 'publishing', 'singapore', 'llc', 'international'
23 ]
24 stop_words.update(custom_noise)
25
26 def clean_text(text):
27     if not isinstance(text, str):
28         return ""
29     text = text.lower()
30     text = re.sub(r'copyright.*', '', text) #ตัดประโยคลิขสิทธิ์ทิ้ง
31     text = re.sub(r'^a-z\s', '', text)
32     words = text.split()
33     words = [w for w in words if w not in stop_words]
34     return " ".join(words)
35
36 print("กำลังทำความสะอาดข้อมูล Title และ Abstract...")
37 df_clean['Clean_Title'] = df_clean['Title'].apply(clean_text)
38 df_clean['Clean_Abstract'] = df_clean['Abstract'].apply(clean_text)
39 df_clean['Combined_Text'] = df_clean['Clean_Title'] + " " + df_clean['Clean_Abstract']
40
41 print("กระบวนการเสร็จสิ้น ชุดข้อมูลพร้อมสำหรับการทำ Vectorization")
42 display(df_clean[['Subject', 'Combined_Text']].head())

```

[nltk_data] Downloading package stopwords to /root/nltk_data...

[nltk_data] Unzipping corpora/stopwords.zip.

กำลังทำความสะอาดข้อมูล Title และ Abstract...

กระบวนการเสร็จสิ้น ชุดข้อมูลพร้อมสำหรับการทำ Vectorization

	Subject	Combined_Text
0	Artificial_Intelligence	using learning progressions guide ai feedback ...
1	Artificial_Intelligence	machine learning small datasets resource const...
2	Artificial_Intelligence	physicsinspired hybrid ai framework mechanisti...
3	Artificial_Intelligence	runtime assurance onboard cotsbased ai safetyc...
4	Artificial_Intelligence	functional guidance wholeprotein virtual scree...

✧ สร้าง Word Cloud เพื่อดู Keyword ยอดฮิตแยกตาม 10 สาขาวิชา (Subject)

```

1 import matplotlib.pyplot as plt
2 from wordcloud import WordCloud
3
4 #หาชื่อสาขาวิชาทั้งหมดที่มีในชุดข้อมูล
5 subjects = df_clean['Subject'].unique()
6
7 #ตั้งค่าขนาดกราฟให้แสดง 5 แถว 2 คอลัมน์ (สำหรับ 10 สาขาวิชา)
8 fig, axes = plt.subplots(5, 2, figsize=(20, 25))
9 axes = axes.flatten()
10

```

```
11
12 for i, sub in enumerate(subjects):          #ดึงข้อความจากคอลัมน์ Combined_Text เฉพาะสาขาวิชานั้น ๆ มารวมกันเป็นก้อนเดียว
13     text_data = " ".join(df_clean[df_clean['Subject'] == sub]['Combined_Text'].tolist())
14
15     #สร้าง Word Cloud
16     wordcloud = WordCloud(
17         width=800,
18         height=400,
19         background_color='white',
20         max_words=100,
21         colormap='viridis',
22         random_state=42
23     ).generate(text_data)
24
25     #วาดกราฟลงในตำแหน่ง (Subplot) ที่กำหนด
26     axes[i].imshow(wordcloud, interpolation='bilinear')
27     axes[i].set_title(f'Subject: {sub}', fontsize=18, fontweight='bold')
28     axes[i].axis('off')
29
30 plt.tight_layout()    #ปรับระยะห่างระหว่างกราฟให้สวยงามและแสดงผล
31 plt.show()
```


