

```
1 import pandas as pd
2 import glob
3 import os
```

```
1 from google.colab import drive
2 drive.mount('/content/drive')
```

Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/drive", force_remount=True).

▼ อ่านไฟล์ CSV

```
1 ##df = pd.read_csv('/content/drive/MyDrive/EDA_ScopusData_Midterm/data/ComputerVisionANDPatternRecognition.csv', encoding='u
2
3 folder_path = '/content/drive/MyDrive/EDA_ScopusData_Midterm/data/'
4 all_files = glob.glob(os.path.join(folder_path, "*.csv")) #หาไฟล์ที่ลงท้ายด้วย.csv
5
6 #ลิสต์สำหรับเก็บดาต้าเฟรมของแต่ละไฟล์
7 df_list = []
8
9 for file in all_files:
10     temp_df = pd.read_csv(file, encoding='utf-8')
11     #ดึงชื่อไฟล์ออกและตัด.csv แล้วสร้างคอลัมน์ subject
12     subject_name = os.path.basename(file).replace('.csv', '')
13     temp_df['Subject'] = subject_name
14
15 #เอาดาต้าเฟรมไปเก็บไว้ในลิสต์
16 df_list.append(temp_df)
17
18 df = pd.concat(df_list, ignore_index=True)
19 print(f"จำนวนข้อมูลทั้งหมด: {df.shape[0]} แถว, {df.shape[1]} คอลัมน์")
20 display(df.head())
```

จำนวนข้อมูลทั้งหมด: 5600 แถว, 23 คอลัมน์

	Authors	Author full names	Author(s) ID	Title	Year	Source title	Volume	Issue	Art. No.	Page start	...	
0	Xia X.; Yuruk N.; Wang Y.; Zhai X.	Xia, Xin (58544876200); Yuruk, Nejla (22959323...	58544876200; 22959323200; 59936586800; 5719268...	Using Learning Progressions to Guide AI Feedba...	2027	Lecture Notes in Computer Science	16585 LNAI	NaN	NaN	195.0	...	https://www.
1	Leite R.; Araújo R.E.	Leite, Renato (60707898100); Araújo, Rui Estev...	60707898100; 23395865700	Machine Learning on Small Datasets Under Resou...	2027	IFIP Advances in Information and Communication...	790 IFIPAICT	NaN	NaN	71.0	...	https://www.
2	Hosseinhashemi S.; Liu Q.; Elsa A.; Saifoori S...	Hosseinhashemi, Somayeh (58629984100); Liu, Qi...	58629984100; 60751131200; 60571652000; 5719771...	Physics-Inspired hybrid AI framework for mecha...	2027	Chemical Engineering Science	338	NaN	124680	NaN	...	https://www.
3	Khalid O.; Gamazo-Real J.-C.; Roibás-Millán E.	Khalid, Omer (60744895700); Gamazo-Real, Jose-...	60744895700; 36503715200; 56808339300	Run-Time Assurance for Onboard COTS-Based AI i...	2027	Lecture Notes in Computer Science	16767 LNCS	NaN	NaN	445.0	...	https://www.
4	Shen A.; Yuan M.; Huang Q.; Feng B.; Du J.; Ma...	Shen, Ao (58769364200); Yuan, Mingzhi (5744468...	58769364200; 57444680700; 59423106600; 5799585...	Functional guidance for whole-protein virtual ...	2027	Information Fusion	138	NaN	104709	NaN	...	https://www.

5 rows × 23 columns

▼ การกรองซ้ำ

```
1 # เก็บเฉพาะบทความที่ไม่ปรากฏซ้ำใน Subject อื่น (เช็คจากชื่อเรื่อง)
2 df = df.drop_duplicates(subset=['Title'], keep=False)
3
4 print(f"จำนวนข้อมูลหลังลบรายการซ้ำ: {df.shape[0]} แถว")
```

จำนวนข้อมูลหลังลบรายการซ้ำ: 5036 แถว

▼ หา Missing Value

```
1 #หา Missing Value ในแต่ละคอลัมน์
2 print("จำนวน Missing Value ในแต่ละคอลัมน์:")
3 missing_count = df.isnull().sum()
4 print(missing_count)
5
6 print("-" * 30)
7
8 #คำนวณเป็นเปอร์เซ็นต์ให้เห็นภาพแจ่มแจ้ง
9 print("ร้อยละ (%) ของ Missing Value ในแต่ละคอลัมน์:")
10 missing_percent = (df.isnull().sum() / len(df)) * 100
11 print(missing_percent.round(2))
12
13 print("-" * 30)
14
15 #แสดงเฉพาะคอลัมน์ที่มี Missing Value
16 missing_only = missing_percent[missing_percent > 0]
17 if not missing_only.empty:
18     print("คอลัมน์ที่พบ Missing Value (เรียงจากมากไปน้อย):")
19     print(missing_only.sort_values(ascending=False).round(2))
20 else:
21     print("ไม่พบ Missing Value ในชุดข้อมูลนี้")
```

```
Issue                3637
Art. No.             2533
Page start           2697
Page end             2700
Cited by              0
DOI                  66
Link                 0
Abstract             0
Author Keywords      336
Index Keywords       340
Document Type        0
Publication Stage     0
Open Access          3325
Source               0
EID                  0
Subject              0
dtype: int64
```

ร้อยละ (%) ของ Missing Value ในแต่ละคอลัมน์:

```
Authors              0.89
Author full names    0.89
Author(s) ID         0.89
Title                0.00
Year                 0.00
Source title         0.00
Volume               11.54
Issue                72.22
Art. No.             50.30
Page start           53.55
Page end             53.61
Cited by             0.00
DOI                  1.31
Link                 0.00
Abstract             0.00
Author Keywords      6.67
```

คอลัมน์ที่พบ Missing Value (เรียงจากมากไปน้อย):

```
Issue          72.22
Open Access    66.02
Page end       53.61
Page start     53.55
Art. No.       50.30
Volume         11.54
Index Keywords  6.75
Author Keywords 6.67
DOI            1.31
Author(s) ID   0.89
Authors        0.89
Author full names 0.89
dtype: float64
```

1 df.columns

```
Index(['Authors', 'Author full names', 'Author(s) ID', 'Title', 'Year',
      'Source title', 'Volume', 'Issue', 'Art. No.', 'Page start', 'Page end',
      'Cited by', 'DOI', 'Link', 'Abstract', 'Author Keywords',
      'Index Keywords', 'Document Type', 'Publication Stage', 'Open Access',
      'Source', 'EID', 'Subject'],
      dtype='object')
```

▼ จัดการ Missing Value


```
1 import re
2 import nltk
3 from nltk.corpus import stopwords
4 nltk.download('stopwords')
5
6 # =====
7 # 1. โค้ดส่วนต้น (ใช้ของเดิมของคุณได้เลย)
8 # =====
9 columns_to_drop = [
10     'Volume', 'Issue', 'Art. No.', 'Page start',
11     'Page end', 'Open Access', 'EID', 'Link', 'Source'
12 ]
13 df_clean = df.drop(columns=columns_to_drop)
14
15 text_fill_cols = ['Author Keywords', 'Index Keywords', 'Authors', 'Author full names', 'Author(s) ID', 'DOI']
16 for col in text_fill_cols:
17     df_clean[col] = df_clean[col].fillna('')
18
19 # =====
20 # 2. โค้ดส่วนกลั่นข้อความ (นำของใหม่มาวางทับตรงนี้)
21 # =====
22 stop_words = set(stopwords.words('english'))
23 custom_noise = [
24     'copyright', 'license', 'springer', 'nature', 'switzerland',
25     'authors', 'exclusive', 'pte', 'ltd', 'rights', 'reserved',
26     'ag', 'publishing', 'singapore', 'llc', 'international'
27 ]
28 stop_words.update(custom_noise)
29
30 def clean_text(text):
31     if not isinstance(text, str):
32         return ""
33     text = text.lower()
34     text = re.sub(r'copyright.*', '', text) # ตัดประโยคลิขสิทธิ์ทิ้ง
35     text = re.sub(r'^a-z\s', '', text)
36     words = text.split()
37     words = [w for w in words if w not in stop_words]
38     return " ".join(words)
39
40 print("กำลังทำความสะอาดข้อมูล Title และ Abstract...")
41 df_clean['Clean_Title'] = df_clean['Title'].apply(clean_text)
42 df_clean['Clean_Abstract'] = df_clean['Abstract'].apply(clean_text)
43 df_clean['Combined_Text'] = df_clean['Clean_Title'] + " " + df_clean['Clean_Abstract']
44
45 print("กระบวนการเสร็จสิ้น ชุดข้อมูลพร้อมสำหรับการทำ Vectorization")
46 display(df_clean[['Subject', 'Combined_Text']].head())
```

```
[nltk_data] Downloading package stopwords to /root/nltk_data...
[nltk_data] Package stopwords is already up-to-date!
กำลังทำความสะอาดข้อมูล Title และ Abstract...
กระบวนการเสร็จสิ้น ชุดข้อมูลพร้อมสำหรับการทำ Vectorization
```

	Subject	Combined_Text
0	Artificial_Intelligence	using learning progressions guide ai feedback ...
1	Artificial_Intelligence	machine learning small datasets resource const...
2	Artificial_Intelligence	physicsinspired hybrid ai framework mechanisti...
3	Artificial_Intelligence	runtime assurance onboard cotsbased ai safety...
4	Artificial_Intelligence	functional guidance wholeprotein virtual scree...

✓ สร้าง Word Cloud เพื่อดู Keyword ยอดฮิตแยกตาม 10 สาขาวิชา (Subject)

```
1 import matplotlib.pyplot as plt
2 from wordcloud import WordCloud
3
4 #หาชื่อสาขาวิชาทั้งหมดที่มีในชุดข้อมูล
5 subjects = df_clean['Subject'].unique()
6
7 #ตั้งค่าขนาดกราฟให้แสดง 5 แถว 2 คอลัมน์ (สำหรับ 10 สาขาวิชา)
8 fig, axes = plt.subplots(5, 2, figsize=(20, 25))
9 axes = axes.flatten()
10
11
12 for i, sub in enumerate(subjects): #ดึงข้อความจากคอลัมน์ Combined_Text เฉพาะสาขานั้น ๆ มารวมกันเป็นก้อนเดียว
13     text_data = " ".join(df_clean[df_clean['Subject'] == sub]['Combined_Text'].tolist())
14
15     #สร้าง Word Cloud
16     wordcloud = WordCloud(
17         width=800,
18         height=400,
19         background_color='white',
20         max_words=100,
21         colormap='viridis',
22         random_state=42
23     ).generate(text_data)
24
25     #วาดกราฟลงในตำแหน่ง (Subplot) ที่กำหนด
26 axes[i].imshow(wordcloud, interpolation='bilinear')
27 axes[i].set_title(f'Subject: {sub}', fontsize=18, fontweight='bold')
28 axes[i].axis('off')
29
30 plt.tight_layout() #ปรับระยะห่างระหว่างกราฟให้สวยงามและแสดงผล
31 plt.show()
```

การสร้าง visualization เป็นไฟล์ HTML

```
1 !pip install pyvis networkx
```

```
Requirement already satisfied: pyvis in /usr/local/lib/python3.13/dist-packages (0.3.1)
Requirement already satisfied: networkx in /usr/local/lib/python3.13/dist-packages (3.6.1)
Requirement already satisfied: ipython<5.3.0 in /usr/local/lib/python3.13/dist-packages (from pyvis) (7.14.0)
Requirement already satisfied: Jinja2<2.9.6 in /usr/local/lib/python3.13/dist-packages (from ipython) (2.11.3)
Requirement already satisfied: pickleshare in /usr/local/lib/python3.13/dist-packages (from ipython) (0.7.5)
Requirement already satisfied: jedi<0.16.1 in /usr/local/lib/python3.13/dist-packages (from ipython) (0.20.0)
Requirement already satisfied: decorator in /usr/local/lib/python3.13/dist-packages (from ipython) (4.4.2)
Requirement already satisfied: prompt-toolkit<3.0.0,!=3.0.1,<3.1.0,>=2.0.0 in /usr/local/lib/python3.13/dist-packages (from ipython) (3.0.48)
Requirement already satisfied: traitlets<4.2 in /usr/local/lib/python3.13/dist-packages (from ipython) (5.7.1)
Requirement already satisfied: matplotlib<3.0.0 in /usr/local/lib/python3.13/dist-packages (from ipython) (3.9.0)
Requirement already satisfied: pexpect<4.3 in /usr/local/lib/python3.13/dist-packages (from ipython) (4.9.0)
Requirement already satisfied: MarkupSafe<2.0 in /usr/local/lib/python3.13/dist-packages (from Jinja2) (2.1.5)
Requirement already satisfied: parsok<0.9.0,>=0.8.6 in /usr/local/lib/python3.13/dist-packages (from jedi) (0.16.0)
Requirement already satisfied: ptyprocess<0.5 in /usr/local/lib/python3.13/dist-packages (from pexpect) (0.7.0)
Requirement already satisfied: wcwidth<0.1.4 in /usr/local/lib/python3.13/dist-packages (from prompt-toolkit) (0.2.13)
```

```
1 from networkx.algorithms.community import greedy_modularity_communities
2
3 print("กำลังสร้าง Network Graph และแบ่งกลุ่มสิ...")
4 G = nx.Graph()
5
6 # 4.1 เพิ่มเส้นเชื่อม (Edges) ก่อน เพื่อให้ระบบวิเคราะห์ความสัมพันธ์ได้
7 for (kw1, kw2), weight in edge_counts.items():
8     if weight > 1: # กรองเฉพาะคู่ที่เจอบ่อยกว่า 1 ครั้ง
9         G.add_edge(kw1, kw2, value=weight, title=f"Co-occurred {weight} times")
10
11 # 4.2 ค้นหาชุมชนของคำศัพท์ (Community Detection)
12 # คำไหนเชื่อมโยงกันบ่อยจะถูกรวมเข้ากลุ่ม (สิ) เดียวกัน
13 communities = list(greedy_modularity_communities(G))
14
15 # สร้าง Dictionary เก็บข้อมูลว่าคำศัพท์ไหนอยู่กลุ่มหมายเลขอะไร
16 node_groups = {}
17 for i, comm in enumerate(communities):
18     for node in comm:
19         node_groups[node] = i
20
21 # 4.3 เพิ่มจุด (Nodes) เข้าไปในกราฟ พร้อมกำหนดขนาดและระบุ Group (PyVis จะแยกสีตาม Group)
22 for kw in G.nodes():
23     kw_size = keyword_counts[kw]
24     kw_group = node_groups.get(kw, 0)
25
26     # อัปเดตข้อมูล Node ทีละตัว
27     G.nodes[kw]['size'] = kw_size
28     G.nodes[kw]['title'] = f"{kw} ({kw_size} papers) - Group {kw_group}"
29     G.nodes[kw]['group'] = kw_group # นี่คือตัวแปรที่ทำให้สีต่างกัน
30
31 # 5. แปลงกราฟเป็นรูปแบบ Interactive ด้วย PyVis และบันทึกเป็น HTML
32 net = Network(height="700px", width="100%", bgcolor="#ffffff", font_color="black", notebook=True)
33 net.from_nx(G)
34
35 # เพิ่มเมนูปรับแต่งกราฟ
36 net.show_buttons(filter_=['physics'])
37
38 # กำหนด Path สำหรับเซฟไฟล์ลง Google Drive
39 html_file_path = '/content/drive/MyDrive/EDA_ScopusData_Midterm/keyword_co_occurrence.html'
40 net.save_graph(html_file_path)
```

```

41
42 print(f"บันทึกไฟล์ HTML Network Graph (แบบแยกสี) สำเร็จที่: {html_file_path}")

```

กำลังสร้าง Network Graph และแบ่งกลุ่มสี...

Warning: When `cdn_resources` is 'local' jupyter notebook has issues displaying graphics on chrome/safari. Use `cdn_resources='in'`
บันทึกไฟล์ HTML Network Graph (แบบแยกสี) สำเร็จที่: /content/drive/MyDrive/EDA_ScopusData_Midterm/keyword_co_occurrence.html

✓ คัดเลือกคอลัมน์ที่เหมาะสมกับการนำมาสร้าง feature vector

การเตรียมและแปลงข้อความในคอลัมน์ดังกล่าวให้เป็น Feature Vector ในรูปแบบเมทริกซ์ตัวเลข (Numerical Matrix) โดยใช้เทคนิค TF-IDF

```

1 from sklearn.feature_extraction.text import TfidfVectorizer
2 from sklearn.preprocessing import LabelEncoder
3
4 #นำ Keywords มาต่อท้าย Combined_Text เพื่อเพิ่มบริบทที่เข้มข้นให้กับโมเดล
5 df_clean['Final_Text'] = df_clean['Combined_Text'] + " " + df_clean['Author Keywords'] + " " + df_clean['Index Keywords']
6
7 #กำหนดคอลัมน์สำหรับ Features (X) และ Target (y)
8 X_raw = df_clean['Final_Text']
9 y_raw = df_clean['Subject']
10
11 #แปลงตัวแปรตาม(y) ให้เป็นหมวดหมู่ตัวเลข 0-9
12 print("กำลังแปลง Target Variable...")
13 encoder = LabelEncoder()
14 y = encoder.fit_transform(y_raw)
15
16 #แปลงข้อความ(X) ให้เป็น Feature Vector (เมทริกซ์ตัวเลข)
17 print("กำลังสร้าง Feature Vector ด้วย TF-IDF...")
18 tfidf_vectorizer = TfidfVectorizer(
19     max_features=5000, # เลือกคำศัพท์ที่มีความสำคัญและพบบ่อยที่สุด 5,000 คำ (ลดขนาดมิติข้อมูลป้องกันเครื่องค้าง)
20     ngram_range=(1, 2) # ให้โมเดลเรียนรู้ทั้งคำเดี่ยว (เช่น "machine") และคำคู่ที่มีกมาด้วยกัน (เช่น "machine learning")
21 )
22
23 X = tfidf_vectorizer.fit_transform(X_raw)
24
25 # ตรวจสอบผลลัพธ์
26 print("-" * 50)
27 print(f"ขนาดของ Feature Matrix (X): {X.shape[0]} ตัวอย่าง, {X.shape[1]} ฟีเจอร์ (คำศัพท์)")
28 print(f"ขนาดของ Target (y): {y.shape[0]} ตัวอย่าง")
29 print("รายชื่อคลาสที่ถูกแปลงเป็นตัวเลข:", encoder.classes_)

```

กำลังแปลง Target Variable...

กำลังสร้าง Feature Vector ด้วย TF-IDF...