

```
1 import pandas as pd
2 import glob
3 import os
```

```
1 from google.colab import drive
2 drive.mount('/content/drive')
```

Drive already mounted at /content/drive; to attempt to forcibly remount, call dr

✓ อ่านไฟล์ CSV

```
1 ##df = pd.read_csv('/content/drive/MyDrive/EDA_ScopusData_Midterm/data/Comp
2
3 folder_path = '/content/drive/MyDrive/EDA_ScopusData_Midterm/data/'
4 all_files = glob.glob(os.path.join(folder_path, "*.csv")) #หาไฟล์ที่ลงท้ายด้วย.
5
6 #ลิสต์สำหรับเก็บดาต้าเฟรมของแต่ละไฟล์
7 df_list = []
8
9 for file in all_files:
10     temp_df = pd.read_csv(file, encoding='utf-8')
11     #ดึงชื่อไฟล์ออกและตัด.csv แล้วสร้างคอลัมน์ subject
12     subject_name = os.path.basename(file).replace('.csv', '')
13     temp_df['Subject'] = subject_name
14
15     #เอาดาต้าเฟรมไปเก็บไว้ในลิสต์
16     df_list.append(temp_df)
17
18 df = pd.concat(df_list, ignore_index=True)
19 print(f"จำนวนข้อมูลทั้งหมด: {df.shape[0]} แถว, {df.shape[1]} คอลัมน์")
20 display(df.head())
```

จำนวนข้อมูลทั้งหมด: 5600 แถว, 23 คอลัมน์

	Authors	Author full names	Author(s) ID	Title	Year	Source titl
0	Xia X.; Yuruk N.; Wang Y.; Zhai X.	Xia, Xin (58544876200); Yuruk, Nejla (22959323...	58544876200; 22959323200; 59936586800; 5719268...	Using Learning Progressions to Guide AI Feedba...	2027	Lecture Notes i Compute Scienc
1	Leite R.; Araújo R.E.	Leite, Renato (60707898100); Araújo, Rui Estev...	60707898100; 23395865700	Machine Learning on Small Datasets Under Resou...	2027	IFIP Advances i Information an Communication.
2	Hosseinhashemi S.; Liu Q.; Eisa A.; Saifoori S...	Hosseinhashemi, Somayeh (58629984100); Liu, Qi...	58629984100; 60751131200; 60571652000; 5719771...	Physics-Inspired hybrid AI framework for mecha...	2027	Chemica Engineerin Scienc
3	Khalid O.; Gamazo-Real J.-C.; Roibás-Millán E.	Khalid, Omer (60744895700); Gamazo-Real, Jose-...	60744895700; 36503715200; 56808339300	Run-Time Assurance for Onboard COTS-Based AI i...	2027	Lecture Notes i Compute Scienc
4	Shen A.; Yuan M.; Huang Q.; Feng B.; Du J.; Ma...	Shen, Ao (58769364200); Yuan, Mingzhi (5744468...	58769364200; 57444680700; 59423106600; 5799585...	Functional guidance for whole-protein virtual ...	2027	Informatio Fusio

5 rows × 23 columns

▼ การกรองซ้ำ

```
1 # เก็บเฉพาะบทความที่ไม่ปรากฏซ้ำใน Subject อื่น (เช็คจากชื่อเรื่อง)
2 df = df.drop_duplicates(subset=['Title'], keep=False)
3
4 print(f"จำนวนข้อมูลหลังลบรายการซ้ำ: {df.shape[0]} แถว")
```

จำนวนข้อมูลหลังลบรายการซ้ำ: 5036 แถว

▼ หา Missing Value

```

1 #หา Missing Value ในแต่ละคอลัมน์
2 print("จำนวน Missing Value ในแต่ละคอลัมน์:")
3 missing_count = df.isnull().sum()
4 print(missing_count)
5
6 print("-" * 30)
7
8 #คำนวณเป็นเปอร์เซ็นต์ให้เห็นภาพแจ่มแจ้ง
9 print("ร้อยละ (%) ของ Missing Value ในแต่ละคอลัมน์:")
10 missing_percent = (df.isnull().sum() / len(df)) * 100
11 print(missing_percent.round(2))
12
13 print("-" * 30)
14
15 #แสดงเฉพาะคอลัมน์ที่มี Missing Value
16 missing_only = missing_percent[missing_percent > 0]
17 if not missing_only.empty:
18     print("คอลัมน์ที่พบ Missing Value (เรียงจากมากไปน้อย):")
19     print(missing_only.sort_values(ascending=False).round(2))
20 else:
21     print("ไม่พบ Missing Value ในชุดข้อมูลนี้")

```

```

Issue          3637
Art. No.       2533
Page start     2697
Page end       2700
Cited by       0
DOI            66
Link           0
Abstract       0
Author Keywords 336
Index Keywords 340
Document Type  0
Publication Stage 0
Open Access    3325
Source         0
EID            0
Subject        0
dtype: int64

```

```

-----
ร้อยละ (%) ของ Missing Value ในแต่ละคอลัมน์:
Authors          0.89

```

```

Page start      53.55
Page end        53.61
Cited by        0.00
DOI             1.31
Link            0.00
Abstract        0.00
Author Keywords 6.67
Index Keywords  6.75
Document Type   0.00
Publication Stage 0.00
Open Access     66.02
Source          0.00
EID             0.00
Subject         0.00
dtype: float64

```

คอลัมน์ที่พบ Missing Value (เรียงจากมากไปน้อย):

```

Issue          72.22
Open Access    66.02
Page end       53.61
Page start     53.55
Art. No.       50.30
Volume         11.54
Index Keywords  6.75
Author Keywords 6.67
DOI            1.31
Author(s) ID   0.89
Authors        0.89
Author full names 0.89
dtype: float64

```

```
1 df.columns
```

```

Index(['Authors', 'Author full names', 'Author(s) ID', 'Title', 'Year',
      'Source title', 'Volume', 'Issue', 'Art. No.', 'Page start', 'Page end',
      'Cited by', 'DOI', 'Link', 'Abstract', 'Author Keywords',
      'Index Keywords', 'Document Type', 'Publication Stage', 'Open Access',
      'Source', 'EID', 'Subject'],
      dtype='object')

```

✓ จัดการ Missing Value

```

1 import re
2 import nltk
3 from nltk.corpus import stopwords
4 nltk.download('stopwords')
5
6 #การจัดการ Missing Value และลดขนาดข้อมูล
7 columns_to_drop = [
8     'Volume', 'Issue', 'Art. No.', 'Page start',
9     'Page end', 'Open Access', 'EID', 'Link', 'Source'

```

```

10 ]
11 df_clean = df.drop(columns=columns_to_drop)
12
13 #เติมค่าว่างในคอลัมน์ข้อความที่เป็น Metadata ด้วยช่องว่าง
14 text_fill_cols = ['Author Keywords', 'Index Keywords', 'Authors', 'Author f
15 for col in text_fill_cols:
16     df_clean[col] = df_clean[col].fillna('')
17
18
19 #คลีนข้อมูลข้อความ
20 stop_words = set(stopwords.words('english'))
21
22 def clean_text(text):
23     if not isinstance(text, str):
24         return ""
25     text = text.lower()
26     text = re.sub(r'^a-z\s', '', text)
27     words = text.split()
28     words = [w for w in words if w not in stop_words]
29
30     return " ".join(words)
31
32 #เอาฟังก์ชันไปประยุกต์ใช้กับคอลัมน์เป้าหมาย
33 print("กำลังทำความสะอาดข้อมูล Title และ Abstract...")
34 df_clean['Clean_Title'] = df_clean['Title'].apply(clean_text)
35 df_clean['Clean_Abstract'] = df_clean['Abstract'].apply(clean_text)
36
37
38 #รวมข้อความเพื่อเพิ่มประสิทธิภาพ เอา Title และ Abstract มารวมกันเป็นฟิเจอร์เดียว
39 df_clean['Combined_Text'] = df_clean['Clean_Title'] + " " + df_clean['Clear
40
41 print("กระบวนการเสร็จสิ้น ชุดข้อมูลพร้อมสำหรับการทำ Vectorization")
42
43 display(df_clean[['Subject', 'Combined_Text']].head()) #ตรวจสอบผลลัพธ์

```

[nltk_data] Downloading package stopwords to /root/nltk_data...

[nltk_data] Package stopwords is already up-to-date!

กำลังทำความสะอาดข้อมูล Title และ Abstract...

กระบวนการเสร็จสิ้น ชุดข้อมูลพร้อมสำหรับการทำ Vectorization

	Subject	Combined_Text
0	Artificial_Intelligence	using learning progressions guide ai feedback ...
1	Artificial_Intelligence	machine learning small datasets resource const...
2	Artificial_Intelligence	physicsinspired hybrid ai framework mechanisti...
3	Artificial_Intelligence	runtime assurance onboard cotsbased ai safetyc...
4	Artificial_Intelligence	functional guidance wholeprotein virtual scree...




✓ สร้าง Word Cloud เพื่อดู Keyword ยอดฮิตแยกตาม 10 สาขาวิชา (Subject)

```

1 import matplotlib.pyplot as plt
2 from wordcloud import WordCloud
3
4 #หาชื่อสาขาวิชาทั้งหมดที่มีในชุดข้อมูล
5 subjects = df_clean['Subject'].unique()
6
7 #ตั้งค่าขนาดกราฟให้แสดง 5 แถว 2 คอลัมน์ (สำหรับ 10 สาขาวิชา)
8 fig, axes = plt.subplots(5, 2, figsize=(20, 25))
9 axes = axes.flatten()
10
11
12 for i, sub in enumerate(subjects):          #ดึงข้อความจากคอลัมน์ Combined_Text
13     text_data = " ".join(df_clean[df_clean['Subject'] == sub]['Combined_Text'])
14
15     #สร้าง Word Cloud
16     wordcloud = WordCloud(
17         width=800,
18         height=400,
19         background_color='white',
20         max_words=100,
21         colormap='viridis',
22         random_state=42
23     ).generate(text_data)
24
25     #วาดกราฟลงในตำแหน่ง (Subplot) ที่กำหนด
26     axes[i].imshow(wordcloud, interpolation='bilinear')
27     axes[i].set_title(f'Subject: {sub}', fontsize=18, fontweight='bold')
28     axes[i].axis('off')
29
30 plt.tight_layout()    #ปรับระยะห่างระหว่างกราฟให้สวยงามและแสดงผล
31 plt.show()

```


```
1 import plotly.express as px
2
3 # 1. เตรียมข้อมูล: นับจำนวนบทความในแต่ละสาขาวิชาจากข้อมูลที่คลีนแล้ว
4 subject_counts = df_clean['Subject'].value_counts().reset_index()
5 subject_counts.columns = ['Subject', 'Count']
6
7 # 2. สร้างกราฟแท่งแบบ Interactive
8 fig = px.bar(
9     subject_counts,
```

```

10 x='Subject',
11 y='Count',
12 title='จำนวนบทความในแต่ละสาขาวิชา (หลังทำ Data Cleaning)',
13 labels={'Subject': 'สาขาวิชา (Subject)', 'Count': 'จำนวนบทความ'},
14 color='Count',
15 color_continuous_scale='Viridis'
16 )
17
18 # 3. แสดงผลกราฟใน Colab ให้ดูก่อน
19 fig.show()
20
21 # 4. บันทึกเป็นไฟล์ HTML ลงใน Google Drive
22 # เปลี่ยน path ให้ตรงกับโฟลเดอร์ที่คุณต้องการเซฟงาน
23 html_file_path = '/content/drive/MyDrive/EDA_ScopusData_Midterm/subject_dis
24 fig.write_html(html_file_path)
25
26 print(f"บันทึกไฟล์ HTML สำหรับส่งงานสำเร็จที่: {html_file_path}")

```

จำนวนบทความในแต่ละสาขาวิชา (หลังทำ Data Cleaning)



บันทึกไฟล์ HTML สำหรับส่งงานสำเร็จที่: /content/drive/MyDrive/EDA_ScopusData_Midterm/su

- ✓ คัดเลือกคอลัมน์ที่เหมาะสมกับการนำมาสร้าง feature **vector**

การเตรียมและแปลงข้อความในคอลัมน์ดังกล่าวให้เป็น Feature Vector ในรูปแบบเมทริกซ์ตัวเลข (Numerical Matrix) โดยใช้เทคนิค TF-IDF

```
1 from sklearn.feature_extraction.text import TfidfVectorizer
2 from sklearn.preprocessing import LabelEncoder
3
4 #นำ Keywords มาต่อท้าย Combined_Text เพื่อเพิ่มบริบทที่เข้มข้นขึ้นให้กับโมเดล
5 df_clean['Final_Text'] = df_clean['Combined_Text'] + " " + df_clean['Author']
6
7 #กำหนดคอลัมน์สำหรับ Features (X) และ Target (y)
8 X_raw = df_clean['Final_Text']
9 y_raw = df_clean['Subject']
10
11 #แปลงตัวแปรตาม(y) ให้เป็นหมวดหมู่ตัวเลข 0-9
12 print("กำลังแปลง Target Variable...")
13 encoder = LabelEncoder()
14 y = encoder.fit_transform(y_raw)
15
16 #แปลงข้อความ(X) ให้เป็น Feature Vector (เมทริกซ์ตัวเลข)
17 print("กำลังสร้าง Feature Vector ด้วย TF-IDF...")
18 tfidf_vectorizer = TfidfVectorizer(
19     max_features=5000,      # เลือกคำศัพท์ที่มีความสำคัญและพบบ่อยที่สุด 5,000 คำ (ลดร
20     ngram_range=(1, 2)     # ให้โมเดลเรียนรู้ทั้งคำเดี่ยว (เช่น "machine") และคำคู่ที่มักม
21 )
22
23 X = tfidf_vectorizer.fit_transform(X_raw)
24
25 # ตรวจสอบผลลัพธ์
26 print("-" * 50)
27 print(f"ขนาดของ Feature Matrix (X): {X.shape[0]} ตัวอย่าง, {X.shape[1]} ฟีเจอร์")
28 print(f"ขนาดของ Target (y): {y.shape[0]} ตัวอย่าง")
29 print("รายชื่อคลาสที่ถูกแปลงเป็นตัวเลข:", encoder.classes_)
```

กำลังแปลง Target Variable...