

การวิเคราะห์ข้อมูลเชิงสำรวจ (EDA) และการเตรียม Feature Vector จากฐานข้อมูล Scopus

ผู้รับผิดชอบโครงการ: นางสาวจุฑพร ทุมชะ รหัสนิสิต 66011212009
 นางสาวเจนจิรา คำปิว รหัสนิสิต 66011212080
 คณะวิทยาการสารสนเทศ สาขาวิทยาการข้อมูลประยุกต์
 มหาวิทยาลัยมหาสารคาม

ที่ปรึกษาโครงการ: รศ. ดร.โอพาริก สุรินทร์

1. กระบวนการทำ EDA (Exploratory Data Analysis)

การรวบรวมข้อมูล: ดาวน์โหลดชุดข้อมูล เป็นไฟล์ CSV จาก Scopus.com จำนวน 10 สาขาวิชา สาขาละ 600 บทความ ได้แก่ สาขา Artificial_Intelligence, Computational Theory AND Mathematics, Computer Graphics AND Computer AidedDesign, Computer Networks AND Communications, Computer Vision AND Pattern Recognition, Hardware AND Architecture, Human ComputerInteraction, Information Systems, Signal Processing, Software โดยใช้ keyword ที่กำหนดจากให้เลือก subject area เฉพาะ Computer Science เท่านั้น

2. การกำจัดข้อมูลซ้ำซ้อน (Data Deduplication)

การกำจัดข้อมูลซ้ำซ้อน: ในการตรวจสอบชื่อบทความ (Title) หากพบว่าบทความใดถูกจัดอยู่ในหลายสาขาวิชา (เช่น อยู่ในทั้ง AI และ Software) ระบบจะลบข้อมูลนั้นทิ้งทั้งหมด เหตุผลเพื่อป้องกันปัญหาความคลุมเครือของคลาส (Class Ambiguity) ซึ่งจะทำให้โมเดล Machine Learning สับสนและลดความแม่นยำในการทำนายลง

3. การจัดการค่าว่าง (Missing Value Handling)

3.1 ลบคอลัมน์ที่ไม่จำเป็น: ตรวจสอบร้อยละของค่าว่าง หากคอลัมน์ใดมีค่าว่างสูงเกินเกณฑ์หรือไม่มีผลต่อการวิเคราะห์ข้อความ (เช่น Volume, Issue, Page) จะถูกตัดทิ้งเพื่อลดขนาดหน่วยความจำ

3.2 เติมเต็มค่าว่าง (Imputation): คอลัมน์ที่จำเป็นต่อการวิเคราะห์ เช่น Author Keywords หรือ Abstract หากมีค่าว่าง จะถูกเติมด้วยค่าว่างแบบ String (Empty String " ") เพื่อไม่ให้เกิด Error ในขั้นตอนการนำข้อความมาต่อกัน

4. การทำความสะอาดข้อความ (Text Preprocessing)

4.1 Case Folding: เปลี่ยนอักษรตัวพิมพ์ใหญ่ให้เป็นตัวพิมพ์เล็กทั้งหมด

4.2 Noise Removal: ใช้ Regular Expression (Regex) ลบตัวเลข เครื่องหมายวรรคตอน และอักขระพิเศษออก

4.3 Copyright Stripping: กำหนด Regex เพื่อสกัดและตัดประโยคประกาศลิขสิทธิ์ของสำนักพิมพ์ (เช่น ข้อความที่เริ่มด้วยคำว่า Copyright, Springer, Nature) ออกจากส่วนท้ายของบทคัดย่อ เนื่องจากเป็นคำขยะ (Noise) ที่ไม่มีความหมายทางวิทยาศาสตร์

4.4 Stop Word Removal: ใช้ไลบรารี NLTK กรองคำเชื่อมภาษาอังกฤษ (เช่น a, an, the, is, in) ออกเพื่อให้โมเดลโฟกัสเฉพาะคำศัพท์สำคัญ

5. การทำ Visualization และความสัมพันธ์กับข้อมูล

5.1 Word Cloud: เป็นกราฟิกแสดงผลความถี่ของคำศัพท์ในแต่ละสาขาวิชา โดยขนาดของตัวอักษรจะสะท้อนถึงจำนวนครั้งที่คำนั้นปรากฏ การสร้าง Word Cloud แยกตามสาขาช่วยให้เห็น คุณลักษณะเฉพาะ (Feature Importance) ของแต่ละคลาสได้อย่างรวดเร็ว ว่าแต่ละวิชามีคีย์เวิร์ดใดเป็นแกนหลัก

5.2 Keyword Co-occurrence Network (HTML): กราฟเครือข่าย Interactive แสดงความสัมพันธ์ของการปรากฏคู่กันของคำสำคัญ

5.2.1 จุด (Nodes): แสดงคำสำคัญทางเทคนิคที่พบในชุดข้อมูล ขนาดของจุดบ่งบอกถึงความนิยม

5.2.2 เส้นเชื่อม (Edges): แสดงความสัมพันธ์ของการปรากฏตัวร่วมกัน (Co-occurrence) ในบทความเดียวกัน หากเส้นหนาหมายความว่าสองเทคโนโลยีนี้มักถูกใช้งานร่วมกันบ่อยครั้ง

5.2.3 การจัดกลุ่ม (Community Detection): สีของจุดที่แตกต่างกันแสดงถึงการจัดกลุ่ม (Clustering) ของเทคโนโลยีที่เป็นศาสตร์ใกล้เคียงกัน ช่วยให้เห็นโครงสร้างความสัมพันธ์แฝงในชุดข้อมูล

5.3 Interactive Bar Chart: กราฟแสดงสัดส่วนปริมาณบทความในแต่ละคลาสหลังจากการคลีนข้อมูล เพื่อประเมินความสมดุลของชุดข้อมูลก่อนนำไปเทรนโมเดล

6. ข้อมูลที่นำไปทำ Feature Vector

6.1 การควบรวมข้อความ (Text Concatenation): ข้อมูลที่คลีนแล้วจาก 'Title' และ 'Abstract' ถูกนำมารวมเป็นฟีเจอร์ใหม่ชื่อ 'Combined_Text' จากนั้นจึงนำคำจาก 'Author Keywords' และ 'Index Keywords' มาต่อท้ายเพื่อสร้างเป็นคอลัมน์ 'Final_Text'

6.2 การสร้าง Feature Vector ด้วย TF-IDF: ข้อมูลใน 'Final_Text' ถูกนำมาแปลงเป็นเมทริกซ์ตัวเลขด้วยเทคนิค TfidfVectorizer ซึ่งจะประเมินน้ำหนักความสำคัญของคำศัพท์จากการปรากฏในบทความเมื่อเทียบกับความถี่ในชุดข้อมูลทั้งหมด

การเข้ารหัสคำตอบ (Label Encoding): ข้อมูลคอลัมน์ 'Subject' หรือ 10 สาขาวิชาเป้าหมาย ถูกแปลงให้อยู่ในรูปแบบหมวดหมู่ตัวเลขด้วย LabelEncoder ขั้นตอนนี้อาจเป็นมากเพราะอัลกอริทึม Machine Learning ต้องอาศัยข้อมูลในรูปแบบตัวเลขเพื่อเรียนรู้รูปแบบ

6.3 การเข้ารหัสเป้าหมาย (Label Encoding): แปลงชื่อสาขาวิชาทั้ง 10 หมวดให้เป็นคลาสตัวเลข 0-9 ทำให้ชุดข้อมูลอยู่ในรูปแบบ Array ทางคณิตศาสตร์ที่พร้อมสำหรับกระบวนการ Machine Learning อย่างสมบูรณ์